

R User Conference Korea 2015

Apache Tajo와 R을 연동한 빅데이터 분석





오늘의 주제: 타조알

- R과 빅데이터 분석
- Tajo 소개
 - 개요와 특징
 - 다양한 환경에서 Tajo 사용하기
- RJDBC를 이용한 Tajo 연동
- Tajo UDF(사용자 정의 함수) 사용
- TajoR 로드맵
- Demo
- Q&A



R과 빅데이터 분석



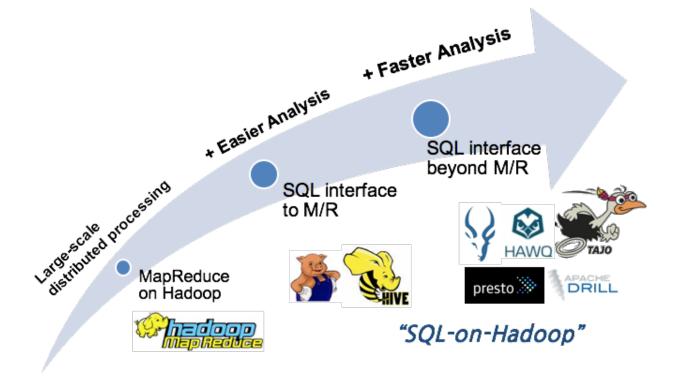
'빅' 데이터에 대처하는 R 분석가의 자세

- 1) R 서버를 업그레이드한다
- 2) 데이터를 샘플링한다
- 3) 병렬처리나 분산처리를 위한 R 패키지들을 이용한다 (bigmemory, snowfall, ..)
- 4) R 외부의 분산 처리 기술을 이용한다 (NoSQL, MapReduce, Hive / RHIPE, RHive, ..)
- 5) 동료 데이터 엔지니어에게 전처리를 부탁한다
- 6) 아몰랑~

R과 빅데이터 기술의 역할 분담



- 메모리에 로드하기 힘든 대용량 데이터 분석의 니즈가 점점 증가
- 확장성있는 저장소로 Hadoop을 사용하는 경우가 많아짐
- 대용량 분산처리에 특화된 빅데이터 기술들이 주목받고 있음 (Hadoop/MapReduce, NoSQL, SQL-on-Hadoop)
- 대용량 전처리는 분산 처리 기술로, 정제된 데이터를 R로 정밀 분석하는 역할 분담 가능





Apache Tajo™: 대용량 분산 Data Warehouse 시스템 (SQL-on-Hadoop)

Tajo의 특징 (자신이 생각하는 중요도를 매겨보세요)

- 친숙한 표준 SQL 질의로 데이터 분석
- 페타바이트급 대용량 데이터를 안정적으로 분산 처리
- MapReduce 기반 기술들 (M/R, Hive, Pig) 보다 평균 3배 이상 빠른 속도
- 응답시간 수초 이내의 인터랙티브 분석 지원
- 다양한 저장소 지원 (HDFS, S3, Swift, Local filesystem, HBase, ElasticSearch ...)
- 다양한 데이터 포맷 직접 분석 가능 (CSV, JSON, Apache log, 커스텀 포맷, ...)
- Tajo API, JDBC 로 다양한 분석툴과 쉽게 연동 (ODBC는 개발 중)
- UDF (User-Defined Function) 지원
- 글로벌 오픈소스 아파치 탑레벨 프로젝트
- 개발자 지원 (한글로 물어보면 바로 답변해 주는 친절한 커미터들)

Tajo로 처리하기 적합한 작업



Tajo로 처리하기 적합한 작업

- 메모리에 로드할 수 없는 큰 데이터
- SQL 로 처리할 수 있는 분석 로직 (eg. 필터링, 집계, 정렬, JOIN)
- 테이블 형태의 정형 데이터
- JSON, Apache log 등 반정형 데이터
- HDFS, Local file, Amazon S3 등 다양한 저장소에 있는 데이터

다른 특화된 기술들이 더 적합한 작업

- iterative 연산이 많은 작업 (eg. machine learning)
- 절차적 처리를 해야 하는 경우
- 실시간 처리가 필요한 경우 (eg. 스트리밍 데이터 분석)

다양한 환경에서 Tajo 사용하기



데스크탑 – Tajo Desktop Package (<u>다운로드</u>)

- 하둡 없이 Mac, Linux에 바로 설치하는 stand-alone Tajo 패키지
- 엑셀로 다루기 힘든 큰 데이터를 변환/Load 없이 바로 SQL로 분석
- 작은 데이터 처리에는 mysql 과 비슷한 속도, 데이터가 커질수록 mysql 보다 빠름

클라우드 - Tajo-as-a-Service (http://taas.gruter.com)

- 아마존 웹서비스 등 클라우드 환경에서 Tajo 클러스터를 쉽게 구성해 주는 서비스
- S3 등 클라우드 저장소에 있는 원본 데이터를 직접 액세스 (No ETL)
- <u>EMR bootstrap action</u> 과 EC2 용 AMI (Amazon Machine Image) 제공

설치형 환경

- 하둡을 확장성 높은 스토리지로 사용하는 것이 보통 (그러나 하둡 없이도 사용 가능)
- Tajo DW 환경을 탑재한 H/W 일체형 제품도 있음 (그루터 G-DPU)

Tajo 와 R 연동 - 데이터 준비



1. Airline 데이터 셋 <u>다운로드</u>

```
$ head /Users/ykko/tajo/data/air2008/air2008.csv

2008,1,3,4,926,930,1054,1100,WN,1746,N612SW,88,90,78,-6,-4,IND,BWI,515,3,7,0,,0,NA,NA,NA,NA,NA
2008,1,3,4,1829,1755,1959,1925,WN,3920,N464WN,90,90,77,34,34,IND,BWI,515,3,10,0,,0,2,0,0,0,32
2008,1,3,4,1937,1830,2037,1940,WN,509,N763SW,240,250,230,57,67,IND,LAS,1591,3,7,0,,0,10,0,0,0,47
2008,1,3,4,617,615,652,650,WN,11,N689SW,95,95,70,2,2,IND,MCI,451,6,19,0,,0,NA,NA,NA,NA,NA
```

2. Tajo 에서 CSV 파일을 External Table 로 연결

```
CREATE EXTERNAL TABLE ext2008 (
   year int, month int, ... )
USING text with ('csvfile.delimiter'='|')
LOCATION 'file:///Users/ykko/tajo/data/air2008/';
```

3. 데이터 변환과 정제 등 전처리 (필요시)

```
CREATE TABLE air2008 AS
SELECT year, month, ...,
CASE airtime WHEN 'NA' THEN null ELSE airtime::INT END as airtime,
...
FROM ext2008;
```

RJDBC 로 Tajo 질의 실행

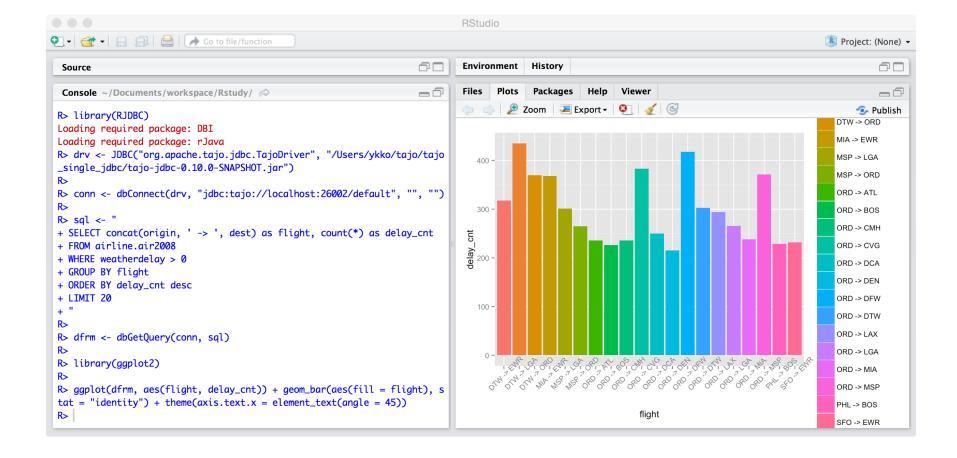


```
library(RJDBC)
drv <- JDBC("org.apache.tajo.jdbc.TajoDriver",</pre>
    "/Users/ykko/tajo/tajo single jdbc/tajo-jdbc-0.10.0-SNAPSHOT.jar")
conn <- dbConnect(drv, "jdbc:tajo://localhost:26002/default", "", "")</pre>
sql <- "SELECT concat(origin, ' -> ', dest) as flight,
               count(*) as delay cnt
        FROM airline.air2008
        WHERE weatherdelay > 0
        GROUP BY flight
        ORDER BY delay cnt desc
        LIMIT 10 "
dfrm <- dbGetQuery(conn, sql)</pre>
                                                      R> dfrm
                                                        flight delay cnt
                                                        DTW -> LGA
                                                                        435
                                                      2 ORD -> DFW
                                                                        418
                                                      3 ORD -> CVG
                                                                        383
                                                        ORD -> MSP
                                                                        371
                                                        DTW -> ORD
                                                                        370
```



```
library(ggplot2)
```

```
ggplot(dfrm, aes(flight, delay_cnt)) + geom_bar(aes(fill = flight), stat
= "identity") + theme(axis.text.x = element_text(angle = 45))
```



대용량 분산 처리 (맛보기)

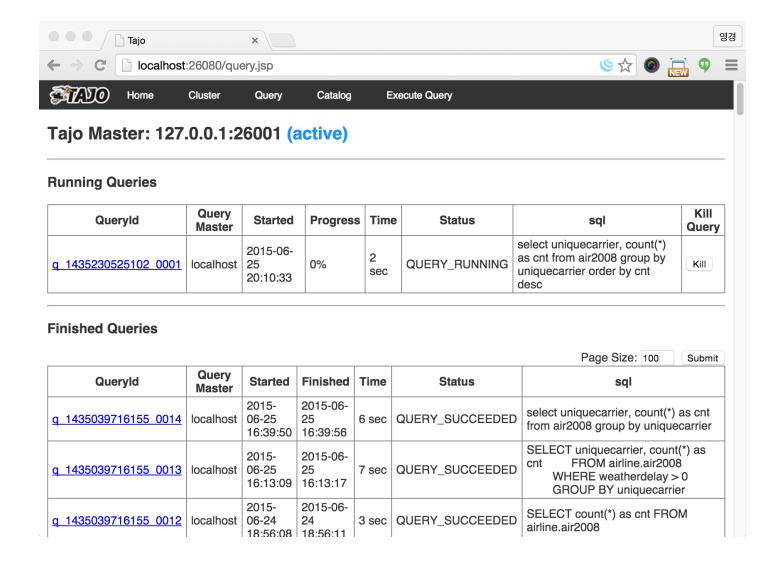


4대로 구성된 Tajo 클러스터(1 master, 3 workers) / TPC-H 100GB 데이터셋

Tajo 관리 UI - 질의 실행 상황 확인



http://tajo-master-server.26080

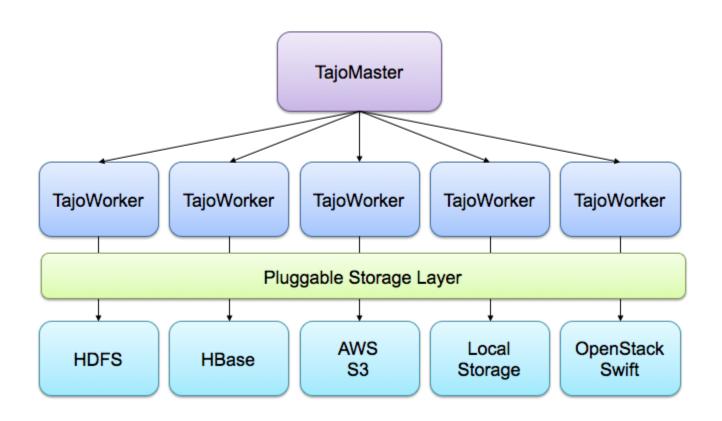


다양한 저장소 지원



하둡, 클라우드 스토리지 등 다양한 저장소를 직접 액세스 이기종 저장소의 데이터간에 조인 처리가 가능

참고: Efficient In-situ Processing of Various Storage Types on Apache Tajo (최현식 박사, Hadoop Summit 2015 발표자료)





Hadoop (HDFS), Amazon S3, Local Filesystem

```
CREATE EXTERNAL TABLE ext2008 ( year text, ... )
USING text with ('csvfile.delimiter'=',')
LOCATION 'hdfs://server:9000/airline/';
-- LOCATION 'file:///Users/ykko/Downloads/';
-- LOCATION 's3://tajo-data-us-east-1/airline/';
```

HBase (cf. HBase Integration)

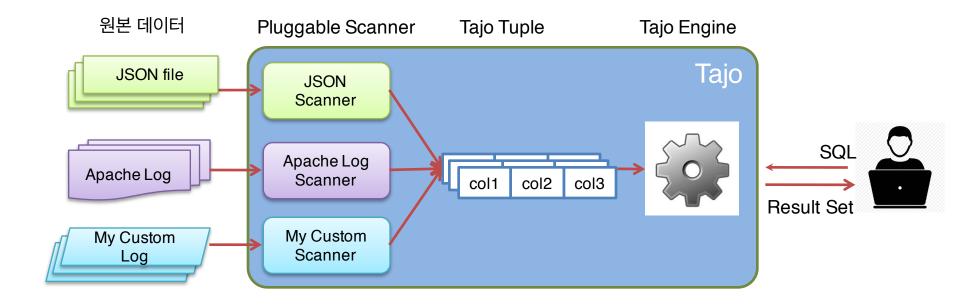
OpenStack Swift (cf. Apache Tajo on Swift)

ElasticSearch, Kafka 지원도 개발 중

다양한 데이터 포맷 지원



CSV, JSON 등 다양한 포맷의 데이터를 직접 액세스 (No ETL)
Custom (De)Serializer 를 플러그인하여 비/반정형 데이터를 변환 없이 바로 SQL 분석 가능ex. 아파치 웹로그 분석



다양한 데이터 포맷 지원 - 웹로그 분석 예제



아파치 웹로그 파일을 그대로

```
LogFormat "%h %l %u %t \"%r\" %>s %b \"%{Referer}i\" \"%{User-Agent}i\"" combined

61.23.4.16 - - [15/Oct/2014:09:00:22 +0900] "GET /main HTTP/1.1" 200 942 "-" "Mozilla/..."

65.13.2.96 - - [15/Oct/2014:09:01:23 +0900] "GET /help HTTP/1.1" 200 242 "-" "Mozilla/..."

65.33.6.10 - - [15/Oct/2014:09:01:23 +0900] "GET /view HTTP/1.1" 200 810 "-" "Mozilla/..."
```

Apache Log SerDe

Tajo External 테이블로 연결

```
CREATE EXTERNAL TABLE web_logs (
    remote_addr TEXT, logname TEXT, remote_user TEXT,
    access_timestamp TIMESTAMP, request_method TEXT,
    request_path TEXT, http_version TEXT, response_status TEXT,
    transferred_bytes INT, referrer TEXT, user_agent TEXT)

USING TEXT WITH (
  'text.serde'='org.apache.tajo.storage.text.ApacheLogLineSerDe',
  'text.delimiter'=' ','text.null'='-')

LOCATION 'file:///Users/ykko/tajo/tajo-desktop-weblog-2.0/data/web-log';
```

SQL로 분석 (eg. 시간대별 트래픽 집계)

```
SELECT extract(hour from access_timestamp) as hh, count(*) as cnt FROM web_logs GROUP BY hh ORDER by hh
```

^{*} 웹로그 SerDe 적용된 브랜치 (https://github.com/hyunsik/tajo/tree/web_log_parser)

Tajo UDF (사용자 정의 함수)



Tajo의 UDF 지원

- SQL로 표현하기 힘들거나 불가능한 로직을 Function으로 구현
- UDF (User-Defined Functions): 사용자가 직접 프로그래밍하여 정의한 함수
- 다양한 언어로 정의 가능. 현재 Java, Python 지원
- eg. Pearson Correlation 을 구하는 Tajo UDF

^{*} corr UDF: https://issues.apache.org/jira/browse/TAJO-1661

TajoR 로드맵



R 과 더 친해지기 위한 Tajo의 로드맵

- CRAN 패키지
- Tajo JDBC의 기능 보완 (eg. 진행률 표시)
- 더 스마트한 샘플링
- Approximate query (eg. time-bound, error-bound)
- R 코드로 만드는 Tajo UDF
- 자주 쓰는 통계, 데이터마이닝 기법에 대한 패키지 코드 지원 (eg. t-test 펑션)
- 동시 질의 지원 (multi-tenancy, Fair scheduler 적용 중)
- Data Frame API 지원
 - Tajo 테이블을 data frame으로 바로 매핑. SQL 코딩 없이 사용 가능하게.

함께 해요



Tajo 아직 안 써보셨다면 한번 시도해 보세요. 쉬워요.

- 개발자에게 추천 <u>Getting Started</u>
- 분석가에게 추천 <u>Tajo Desktop Package</u>
- 클라우드 사용자에게 추천 EMR bootstrap action

TajoR 함께 만들어요

- 사용자 특히 분석가의 feedback이 무척 소중합니다
- 코드 기여 대환영입니다

Tajo 커뮤니티는 활짝 열려있습니다.

- Apache Tajo 웹사이트: http://tajo.apache.org
- 한국 Tajo 사용자 그룹 : <u>구글 그룹스</u> / <u>페이스북 페이지</u>





GRUTER: YOUR PARTNER IN THE BIG DATA REVOLUTION

Phone +82-2-508-5911

Fax +82-2-508-5912

E-mail contact@gruter.com

Web www.gruter.com